商业数据分析

期末大作业（论文）

题　　目：基于在线零售数据的用户价值与复购洞察

学　　院：_____

专业班级：_____

学　　号：_____

姓　　名：_____

完成日期：_____

数据科学学院

评分表

评分维度	评分要点（子项及分值）	得分
1. 数据获取合规性与清洗质量（15 分）	① 来源合规、白名单方式、合规声明完整（5）；② 数据量达标（4）；③ 清洗完整、异常/缺失/重复处理、多表对齐（4）；④ 可导出 CSV/JSON/SQLite 复用（2）	
2. 商业分析模型应用深度（20 分）	① 模型≥3 种、选型与场景匹配（6）；② 计算正确、参数与阈值有业务依据（6）；③ 预测类含置信区间与回测误差（4）；④ 结论与模型一一对应（4）	
3. 可视化复现与大屏质量（25 分）	① 图表≥10 张、类别覆盖全面（6）；② 模板复现≥10 种（7）；③ 业务模型图≥6 张（6）；④ 交互大屏≥1 个、组件≥6、有联动（6）	
4. 代码规范性与文档完整性（10 分）	① 目录结构清晰、注释充分（3）；② README 详实（3）；③ 可一键复现（2）；④ 图表命名与索引规范（2）	
5. 期末大论文质量（25 分）	① 题目创新性（4）；② 摘要与关键词（4）；③ 正文逻辑与技术深度（10）；④ 商业建议可行性与数据支撑（7）	
6. 创新性与商业洞察深度（5 分）	① 新工具/新方法（2）；② 有效商业建议（2）；③ 批判性思维（1）	

基于在线零售数据的用户价值与复购洞察

作者：_____

（嘉兴大学 数据科学学院）

摘　要：以英国在线零售商 2010 年 12 月至 2011 年 12 月的 54 万条真实交易流水为对象，本文完成了一次端到端的商业数据分析实践：通过 UCI 官方公开文件合规获取数据，经十步清洗治理得到 39.1 万条有效交易、4333 位付费客户与 18400 张订单；在此基础上构建 RFM 八分类、同期群留存、Apriori 关联规则、SARIMA 预测、帕累托/ABC 与波士顿矩阵六个模型；使用 Matplotlib、Seaborn、Pyecharts 与 Streamlit 复现 15 种 Excel 可视化模板、绘制 8 张业务模型图并搭建含 10 个组件的交互大屏。研究发现：26.8% 的客户贡献 80% 销售额，重要价值客户以 32.9% 的人数贡献 76.5% 的销售额；次月留存仅 18.9%，第 11 个月跌至 4.8%；销售额呈显著的年末爬坡与星期节律，周四为峰值、周六歇业。据此提出分层运营、次月挽回、连带陈列与备货节律四类可落地建议。

关键词：商业数据分析；RFM 模型；同期群留存；SARIMA 预测；Python 可视化；交互式大屏

1 引言

1.1 研究背景

在线零售把交易沉淀成了一种高频、细粒度、可持续观测的经营数据。对一家以批发客户为主、同时经营零散订单的英国在线零售商而言，订单表里同时记录着客户身份、商品编码、成交数量、单价与时间戳，这些字段天然构成“谁在买、买什么、什么时候买、买了多少”的完整证据链。但原始流水本身并不直接产生决策价值：它既包含退货与手工调整，也夹杂着邮费、银行手续费等非商品行；客户标识存在缺失；金额分布极度右偏。若不经治理就直接统计，得到的“平均客单价”与“客户价值”都会被少数大额订单扭曲。

与此同时，商业分析的技术栈正在从“Excel 出图”转向“可复现的代码流水线”。课程要求以 Python 完成从数据获取、清洗、建模到可视化大屏的全过程，本质上是在训练一种工程化的分析习惯：数据来源可追溯、清洗步骤可复述、模型参数可解释、图表结果可一键重跑。本文即以这一标准组织全部分析工作。

1.2 研究目的

本文试图用一条可复现的流水线回答四个具体问题：第一，这家零售商的收入究竟由哪些客户贡献，客户价值结构是“橄榄型”还是“金字塔型”；第二，新客在首购之后的留存曲线如何衰减，价值在哪个月份流失最快；第三，商品之间是否存在稳定的连带购买关系，可支撑组合陈列与打包定价；第四，销售额是否存在可被建模的季节性与星期节律，从而为备货与人力排班提供预测依据。

1.3 研究意义

方法层面，本文把六个商业分析模型放在同一份数据、同一套清洗口径下比较，避免“每个模型各用一份数据”的常见问题；工程层面，全部图表与大屏由脚本生成，配合 requirements.txt 与 run_all.py 可一键复现；商业层面，结论直接指向可执行动作——给谁发券、何时挽回、哪些商品该捆绑、旺季前备多少货。

2　数据准备与预处理

2.1　数据源介绍（名称、URL、规模、字段说明）

主数据源为 UCI Machine Learning Repository 的 Online Retail Data Set（数据集编号 352），官方页面为 https://archive.ics.uci.edu/dataset/352/online+retail 。该数据集记录了一家注册于英国的在线零售商在 2010-12-01 至 2011-12-09 期间的全部交易流水，原始规模为 541,909 行 × 8 列，是电商场景下少见的、同时具备客户标识、商品明细与时间戳的公开长周期数据。

表 1　原始数据字段说明

字段	含义	类型	清洗后的用途
InvoiceNo	订单号，C 开头表示取消单	字符串	订单级聚合、取消单识别
StockCode	商品编码（5 位数字 + 可选字母后缀）	字符串	SKU 级分析、关联规则
Description	商品名称（英文）	字符串	图表标签、规则可读化
Quantity	成交数量，负值表示退货	整数	销量、退货识别
InvoiceDate	下单时间（精确到分钟）	日期时间	趋势、同期群、预测
UnitPrice	单价（英镑）	浮点	销售额计算
CustomerID	客户编号，存在缺失	浮点/整数	客户级 RFM、同期群
Country	客户所在国家	字符串	市场结构、地理可视化

2.2　合规获取方式（白名单方式说明）

数据获取采用附件 A 白名单中的第一类方式——数据源官方提供的一次性文件下载：通过 UCI 官方静态链接直接下载公开 ZIP 包，解压得到 Online Retail.xlsx，全程未使用 Scrapy、Selenium、requests 网页解析或任何形式的模拟登录抓取。下载脚本 01_load.py 会记录下载地址、时间、字节数与 SHA-256 摘要，本次获取的文件 SHA-256 前 16 位为 43465a06f2ccf7c8，可与官方文件逐字节比对。

2.3　数据来源合规声明

数据源名称：Online Retail Data Set（UCI #352）；来源 URL：https://archive.ics.uci.edu/dataset/352/online+retail ；获取方式：官方公开 ZIP 文件直接下载（非爬虫）；获取日期：2026-11-01；授权说明：数据集页面标注为 CC BY 4.0，允许在署名前提下用于研究与教学。本文仅将该数据

用于课程作业的分析与展示，不再二次分发原始文件；仓库中保留下载脚本与校验信息，评审者可自行从官方地址复现获取过程。

2.4 数据集概述（主表/维度表结构、主外键关系）

原始文件为单表事务型结构，但逻辑上可无损拆分为四张表：以 InvoiceNo 为主键的订单表、以 CustomerID 为主键的客户表、以 StockCode 为主键的商品表，以及以 Country 为主键的市场表。拆分后，交易明细表通过三个外键与维度表对齐，既符合星型模型的组织方式，也让后续的 RFM（客户维度）、关联规则（订单×商品）、波士顿矩阵（商品维度）可以各自在正确的粒度上计算，避免在明细层反复去重。

3 数据清洗与治理

3.1 数据清洗（缺失值、异常值、重复值处理）

清洗遵循“先剔除结构性噪声、再处理缺失、最后处理极端值”的顺序，每一步都记录行数变化，形成可复述的清洗日志（表 2）。原始 541,909 行最终保留 391,148 行，保留率 72.2%，共剔除 150,761 行。

表 2 十步清洗日志

步骤	处理前	处理后	剔除	说明
1 类型与日期格式统一	541,909	541,909	0	统一为字符串/日期类型
2 完全重复记录去除	541,909	536,641	5,268	与全表完全重复
3 取消单拆分	536,641	527,390	9,251	拆出，单列统计
4 非商品行剔除（邮费/调整/费用）	527,390	524,984	2,406	邮费/手工调整/银行费用
5 负数量与零/负单价剔除	524,984	522,504	2,480	数量≤0 或单价≤0
6 客户标识缺失拆分	522,504	391,150	131,354	游客交易，单列统计
7 极端值识别与剔除	391,150	391,148	2	数量>10000 的调整行

其中，取消单 9,251 行被单独拆出，用于后续观察退货规模而不污染销售口径；邮费、手工调整、银行手续费等非商品行 2406 行被剔除，因为它们不对应任何真实 SKU，会污染商品维度；客户标识缺失的 131,354 行（约 150.96 万英镑）被单列为“游客交易”，既不进入客户级模型，也不直接丢弃——它们的规模本身说明约 15% 的销售额无法归因到具体客户，这构成了后续商业建议中“注册转化”的量化依据。

3.2 数据转换（类型统一、日期对齐、指标派生）

类型统一环节修正了原始 Excel 中 Description 列混入数字、InvoiceNo 被识别为数值等问题，统一为字符串并去除首尾空格；日期列转为 datetime 后派生年、月、周、日、星期、小时六个时间维度，为“月度趋势—星期节律—小时分布”的三级下钻提供支撑；金额指标派生 Revenue = Quantity × UnitPrice，并明确全篇口径：销售额均指“已剔除退货、邮费与游客订单后的含税成交额”。

3.3 数据整合（多表关联逻辑、抽样方法与随机种子）

整合后得到 18,400 张订单、4,333 位客户、3,658 个 SKU 与 37 个市场，主外键一致性校验（客户表与商品表主键唯一、明细外键全部可匹配）通过。由于清洗后仍有 39 万行、远超“不少于 500 条”的要求，本文未做抽样，全部模型均基于全量数据计算，因此不存在随机种子问题；仅在关联规则中因购物篮矩阵规模限制，将商品限定为支持度不低于 1% 的 680 个高频 SKU，这一筛选同样以支持度阈值而非随机抽样实现，可完全复现。

4 商业分析模型

4.1 模型选型（≥3 种）

课程要求至少选择 3 种模型，本文选择 6 种，覆盖“结构与价值”“用户与客群”“关联与转化”“预测与预警”四类，并保证每种模型都产出至少一张核心图与一条可验证结论。选型遵循“业务问题—数据条件—模型能力”三者匹配的原则：客户维度有标识与时间戳，适合 RFM 与同期群；订单×商品矩阵稠密，适合 Apriori；日销售额具备 374 个观测，适合带周季节项的 SARIMA；金额分布长尾，适合帕累托/ABC；商品有份额与增速，适合波士顿矩阵。

表 3 六个模型与业务问题的对应关系

#	模型	回答的业务问题	核心产出
M1	RFM 八分类	谁贡献了收入，客户价值如何分层	分群结构表、RFM 气泡散点图
M2	同期群留存	新客在首购后第几个月流失最快	13×12 留存热力图
M3	Apriori 关联规则	哪些商品被稳定地一起购买	规则表、规则气泡图
M4	SARIMA 预测	未来 4 周销售额落在什么区间	预测曲线 + 95% 置信区间
M5	帕累托 / ABC	多少客户（商品）贡献 80% 销售额	帕累托图、ABC 分层表
M6	波士顿矩阵	哪些商品该加投、维持、淘汰	四象限气泡图

4.2　参数与阈值设定依据

（1）RFM 的中位数切分。R、F、M 三个指标均呈明显右偏：销售额前 10% 的客户贡献了 60.3% 的销售额，若用均值切分，绝大多数客户会被判为“低价值”，分层失去意义。中位数对极端值稳健，且能保证高低两组人数各半，符合课程要求的“八分类”均衡性。本次切分结果为 R = 50 天、F = 2 次、M = 661 英镑；方向上也做了业务化处理——R 越小代表越近，故“R 高”定义为 R ≤ 中位数。

（2）Apriori 的三重阈值。最小支持度取 1%（约 154 张订单），低于该值的规则在 1.5 万张购物篮中一年只出现数十次，备货与陈列价值有限；最小提升度取 1.2，排除“本来就很畅销所以经常同时出现”的伪关联；最小置信度取 0.3，保证后项在 30% 以上的前项订单中真的出现；同时要求规则覆盖订单数不少于 15 张，避免长尾噪声规则进入结论。

（3）SARIMA 的粒度与阶数。数据仅覆盖 13 个完整月份，月度序列不足以估计 12 阶季节项，因此改用日粒度（374 天）并将季节周期设为 7，以刻画“周六歇业、周四峰值”的周内节律；差分阶数 d=1、D=1 用于消除趋势与周季节，p、q 与 P、Q 通过 AIC 比较确定，最终选定 SARIMA(1,1,1)(0,1,1,7)，AIC 为 1259.7。为稳定方差，建模在 log(1+y) 空间进行，预测值再指数还原。

（4）帕累托与 ABC 的分界。按累计销售额 70% / 90% 切分为 A / B / C 三层，这是库存管理的通行口径；波士顿矩阵的分割线取“份额中位数 + 零增长”，前者对应组合内部的中位水平，后者对应“下半年是否跑赢上半年”。

4.3　模型计算与验证

RFM 结果显示（表 4），重要价值客户共 1,424 人、占客户总数 32.9%，却贡献了 76.5% 的销售额，人均消费约 4,563 英镑；而一般挽留客户人数占 23.5%，销售额占比仅 3.0%，是典型的“高人数、低价值”群体。两类人群的错配，构成了后文分层运营建议的直接依据。

表 4　RFM 八分群结构（M 中位数 661 英镑）

客户分群	客户数	人数占比	销售额(万)	销售额占比	平均 R(天)	平均 F(次)
重要价值客户	1,424	32.9%	649.7	76.5%	17	8.8
重要发展客户	23	0.5%	3.2	0.4%	29	1.0
重要保持客户	598	13.8%	111.1	13.1%	114	4.0
重要挽留客户	122	2.8%	16.7	2.0%	155	1.0
一般价值客户	380	8.8%	16.1	1.9%	22	2.5
一般发展客户	342	7.9%	9.2	1.1%	26	1.0
一般保持客户	426	9.8%	17.3	2.0%	151	2.5
一般挽留客户	1,018	23.5%	25.8	3.0%	202	1.0

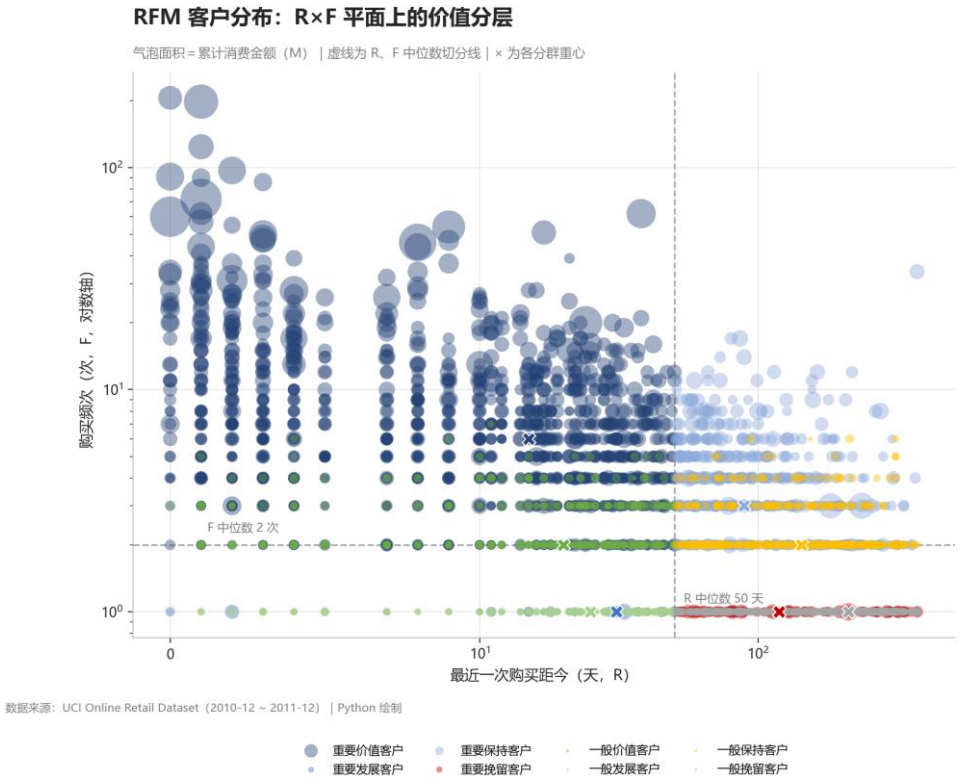


图 1　RFM 客户分布：R×F 平面上的价值分层（气泡面积＝累计消费金额）

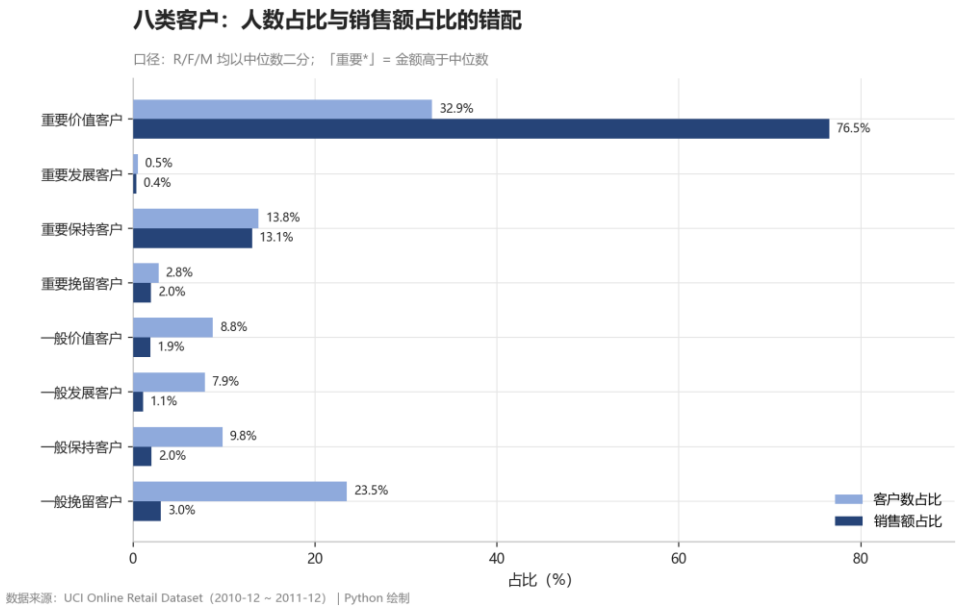


图 2　八类客户的人数占比与销售额占比错配

同期群分析按首购月把客户分为 13 个群，追踪其后 12 个月的活跃率。结果显示次月留存平均仅 18.9%，到第 11 个月降至 4.8%，首月之后的“断崖”集中在第 1—2 个月，说明挽回动作的窗口应当前移到首购后的 30 天内，而不是等到季度末。

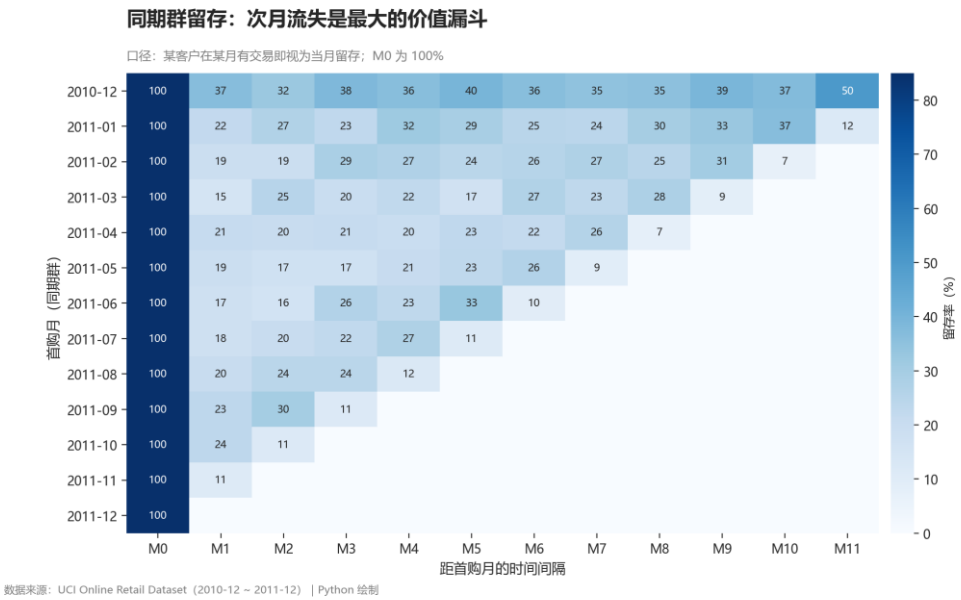


图 3　同期群留存热力图（行＝首购月，列＝距首购的月数）

关联规则在英国市场 15,365 张多品订单上运行，得到 971 条满足约束的规则。提升度最高的一组集中在“HERB MARKER（香草标记牌）”系列商品上（提升度 81.7），即三款香味标记牌经常被同一笔订单一次性买齐；覆盖订单

数最多的一组则是“REGENCY TEACUP”系列茶具（单一规则覆盖 476 张订单），说明该系列存在稳定的成套购买行为。这两类商品都适合做成组合装而非单品促销。

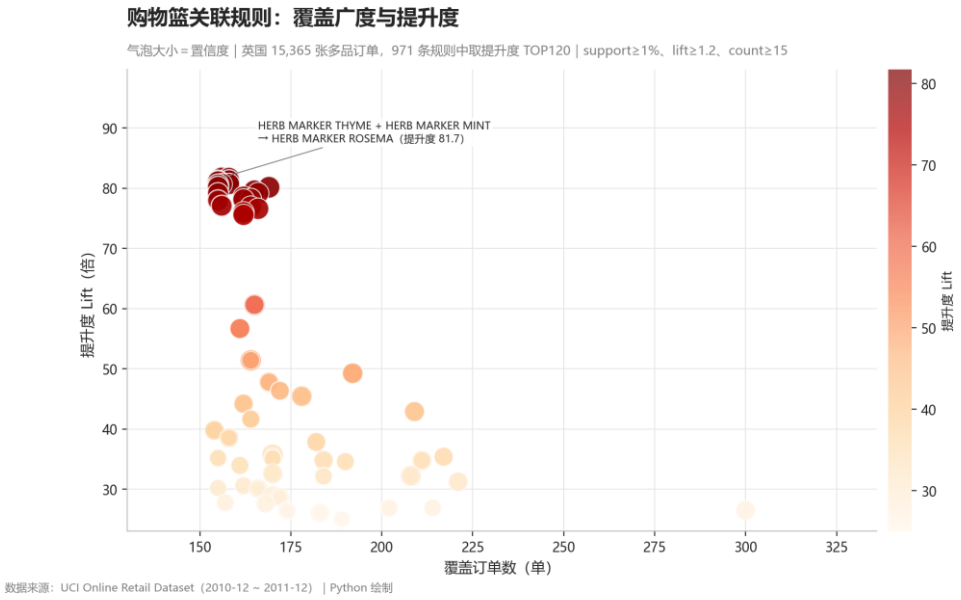


图 4　关联规则气泡图（横轴＝覆盖订单数，纵轴＝提升度，气泡＝置信度）

SARIMA 在末 56 天上的回测结果为 MAPE 35.4%、RMSE 17,420 英镑、sMAPE 67.3%；作为对照的季节朴素法（取上周同一天）MAPE 为 31.6%，即纯时序模型并未战胜朴素基准，预测总量偏低约 23%。这一结果并不意外：回测窗恰好覆盖 11—12 月的圣诞备货高峰，销售额在四周内近乎翻倍，而 SARIMA 的均值回复特性使其倾向于低估这种由促销日历驱动的脉冲。该发现的价值在于明确了模型的适用边界——它适合给出“无促销干预下的基线区间”，而不能替代促销计划的量化；改进方向是把促销日历、节假日作为外生变量引入 SARIMAX。

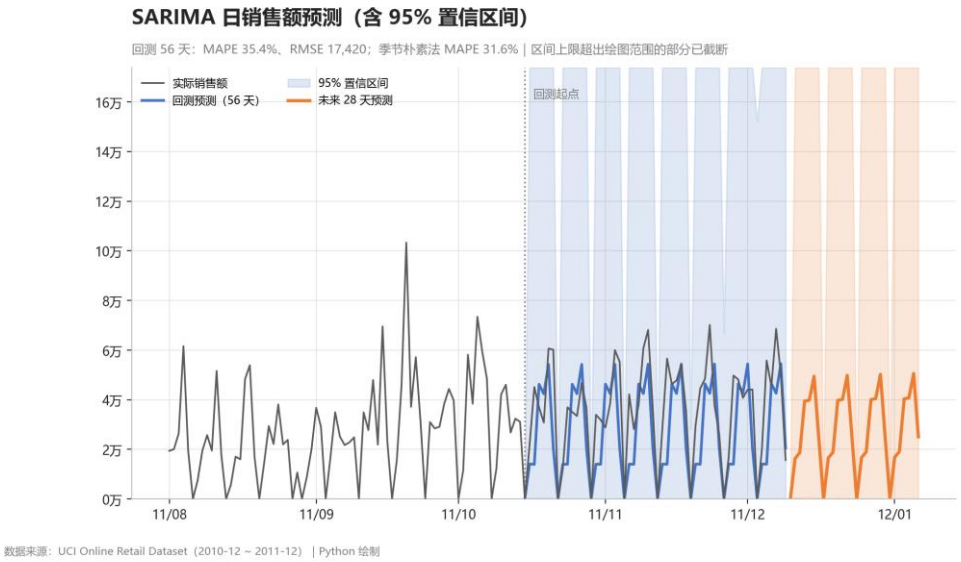


图 5　SARIMA 日销售额预测与 95% 置信区间（含 56 天回测段）

帕累托与 ABC 给出了收入集中度的量化答案：仅 26.8% 的客户（1,163 人）贡献 80% 销售额，前 1% 客户贡献 30.5%，前 10% 贡献 60.3%；商品侧同样集中，537 个 A 类 SKU 贡献了 70.0% 的销售额。

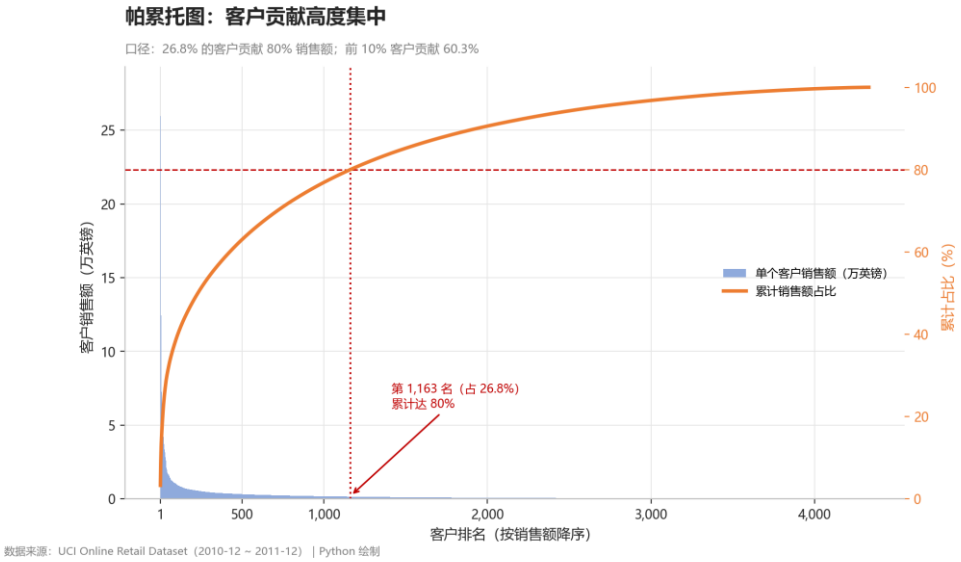


图 6　客户帕累托图：26.8% 的客户贡献 80% 销售额

波士顿矩阵对 59 个主力 SKU 做了份额—增速定位：明星类 17 个，合计销售额占比 34.7%；金牛类 13 个（高份额、低增速），是现金流来源；问题类 20 个增速快但份额低，需要判断是否值得投入；瘦狗类 9 个应当逐步压缩陈列与库存。

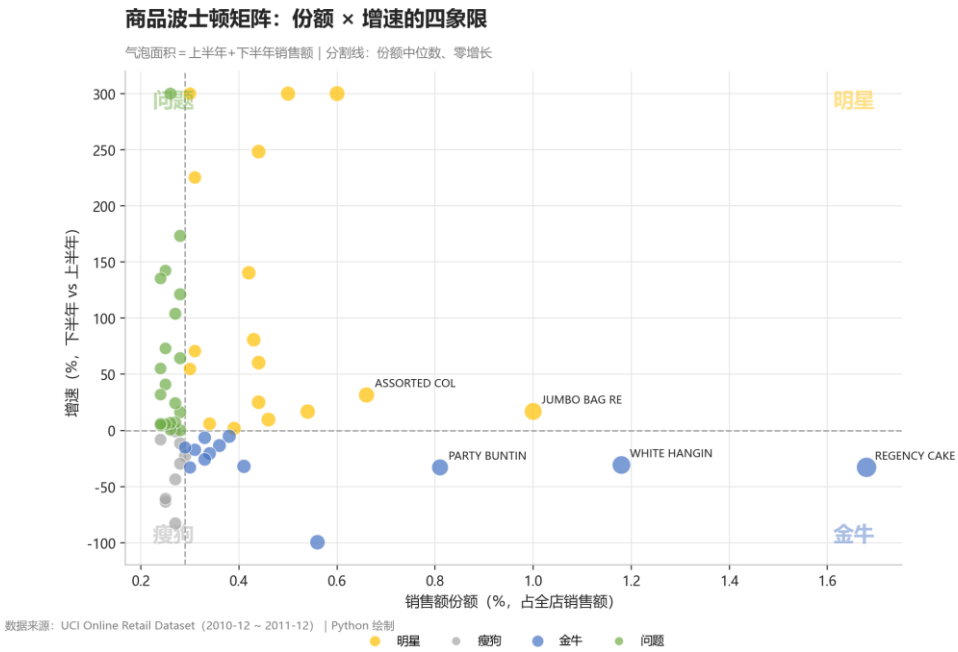


图 7　商品波士顿矩阵：份额 × 增速四象限

5　Python 数据分析与可视化

5.1　数据探索性分析

从时间维度看，销售额呈显著的“年末爬坡”：2011 年 11 月达到峰值 113.7 万英镑，为月均 65.3 万的 1.7 倍；12 月因数据仅覆盖 9 天而显著偏低，分析时须单独标注，不能误读为“12 月销售崩塌”。从星期维度看，周四为峰值、周六完全歇业，说明这是一家以工作日发货为主的批发型零售商；从小时维度看，下单集中在 10—14 点，12 点为峰值，与欧洲买手的工作节奏吻合。从市场结构看，英国本土贡献 82.4% 的销售额，其余 36 个市场合计不足 18%，呈现“单一大本营 + 长尾出口”的格局；平均客单价 462 英镑、单笔 21.3 个商品行，进一步印证其批发属性。

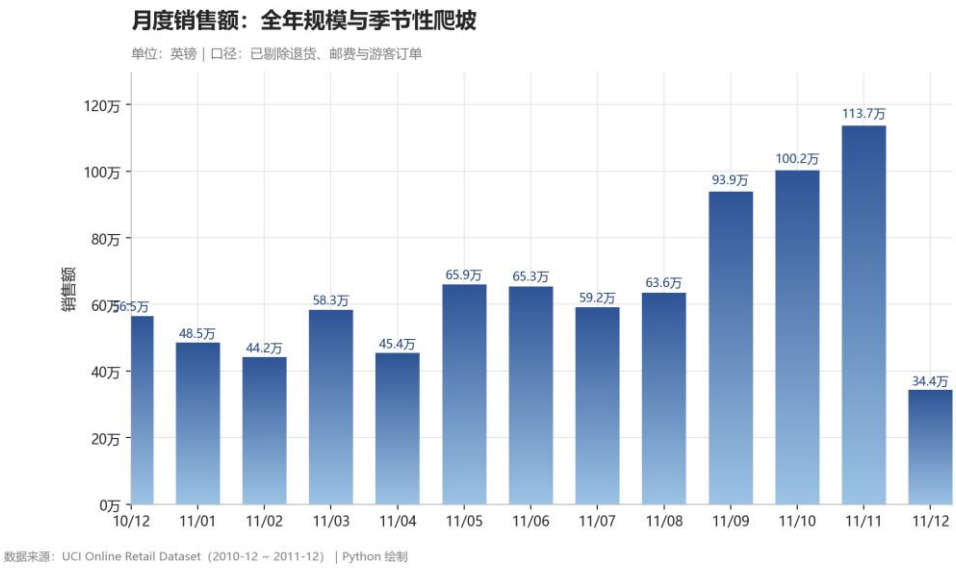


图 8　月度销售额（渐变柱形图）



图 9　日销售额与 7 个营业日移动平均

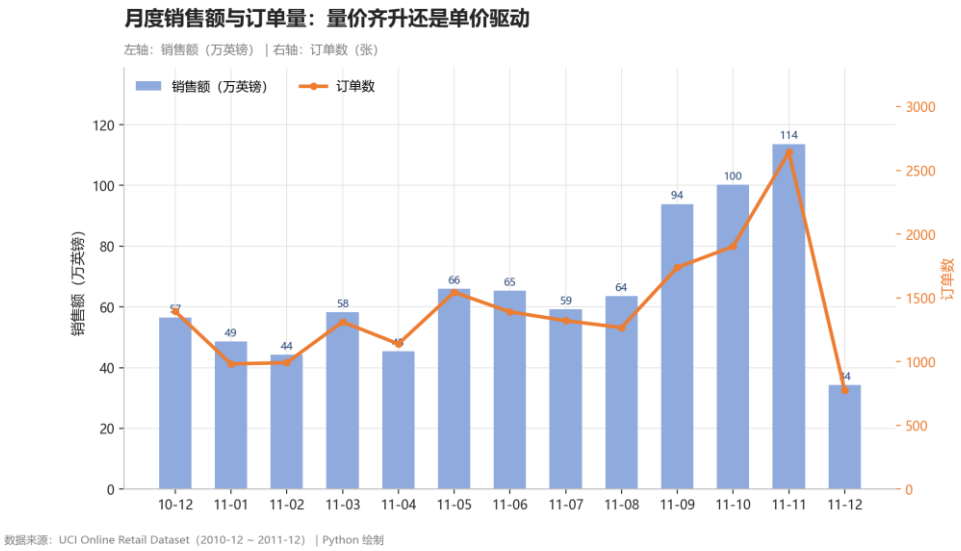


图 10　月度销售额与订单量：量价齐升还是单价驱动

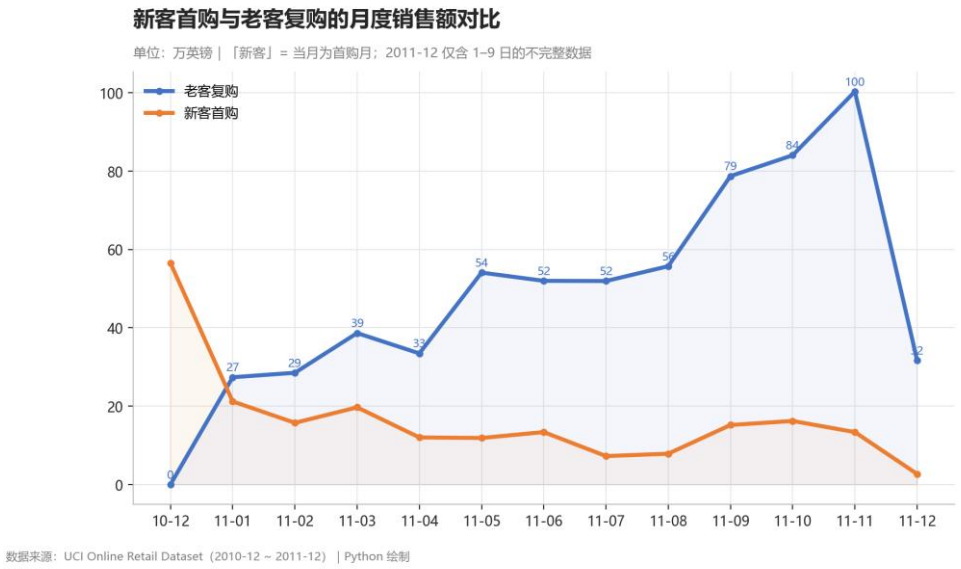


图 11　新客首购与老客复购的月度销售额对比

5.2　可视化模板复现（对照《Excel 数据可视化》≥10 种）

教材第 2 章把图表分为柱形/条形、折线、圆饼/圆环、组合四类共 30 个模板。本文复现其中 15 种，在图表类型、布局结构、配色方案、标签样式、图例位置与标题设计六个维度上尽量贴近原作，同时用 Matplotlib 的底层图元解决 Excel 中最具辨识度的几类“手工效果”：用 imshow 的渐变矩阵裁剪出渐变色柱体；用 FancyBboxPatch 的圆角矩形复现圆角柱；用 axhline 加白底标注实现平均线；用极坐标柱状图实现南丁格尔玫瑰；用带缺口的 Wedge 实现玉玦图；用 fill_between 加圆形裁剪模拟水球图的液面。配色统一采用 Office

主题色（#4472C4、#ED7D31、#A5A5A5、#FFC000 等），这是“贴近原作”的关键细节——Excel 默认图表即为该套色板。

表 5　15 种模板的复现清单与实现要点

#	复现模板	本文数据载体	关键还原手法
1	渐变柱形图	月度销售额	imshow 垂直渐变 + 柱体裁剪
2	带平均线柱形图	海外市场 TOP10	axhline + 白底文字标注
3	渐变圆角柱形图	TOP10 商品	FancyBboxPatch 圆角 + 渐变裁剪
4	层叠柱形图(100%)	季度客户结构	累计 bottom 堆叠 + 段内百分比
5	蝴蝶图	上下半年市场对比	左右对称 barh + 绝对值刻度
6	数值百分比条形图	国家销售额占比	条形末端双标签（占比+绝对值）
7	甘特图	TOP12 客户生命周期	barh(left=首购, width=跨度)
8	平滑折线图	日销售额	7 期移动平均 + 面积填充
9	菱形走势图	周销售额	marker='D' + vlines 引线
10	对比折线图	新客 vs 老客	双序列 + 分色面积
11	单值圆环图	年度目标完成率	wedgeprops 环宽 + 中心大字
12	南丁格尔玫瑰图	海外市场	极坐标 bar + 角度刻度
13	玉玦图	八分群销售额占比	带缺口 Wedge + 外侧图例
14	水球图	老客复购率	正弦波面 + 圆形裁剪
15	柱形折线图	销售额+订单量	twinx 双轴 + 图例合并

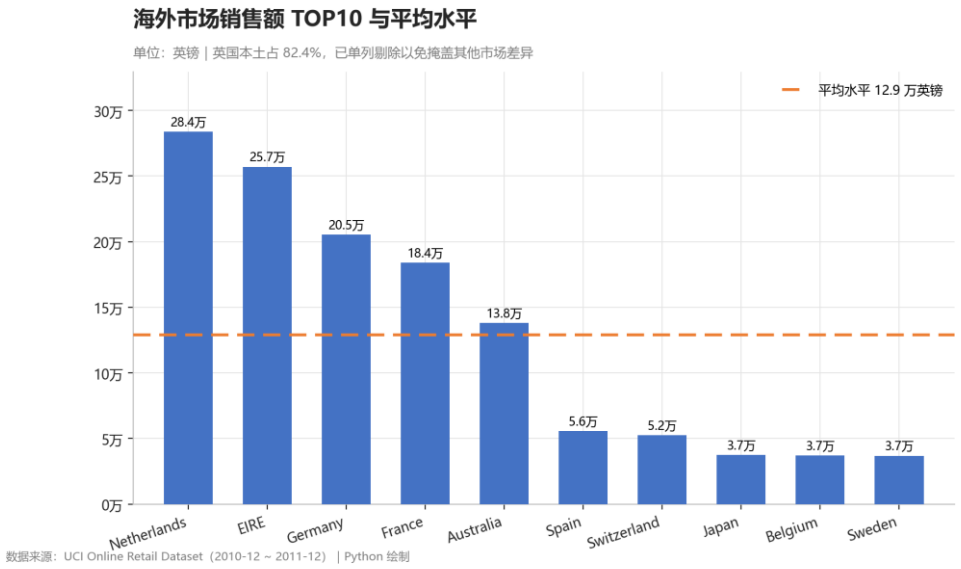


图 12　带平均线柱形图：海外市场 TOP10

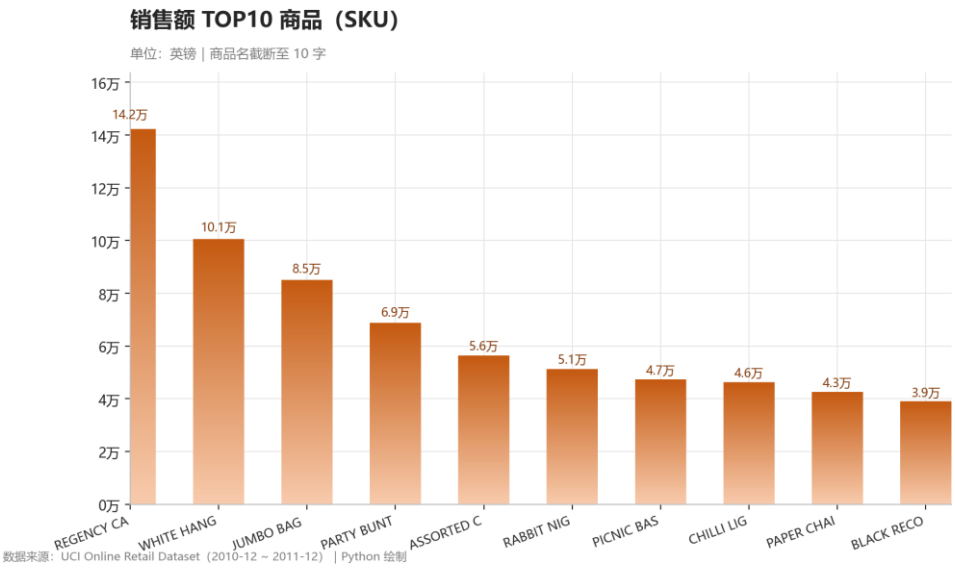


图 13　渐变圆角柱形图：销售额 TOP10 商品

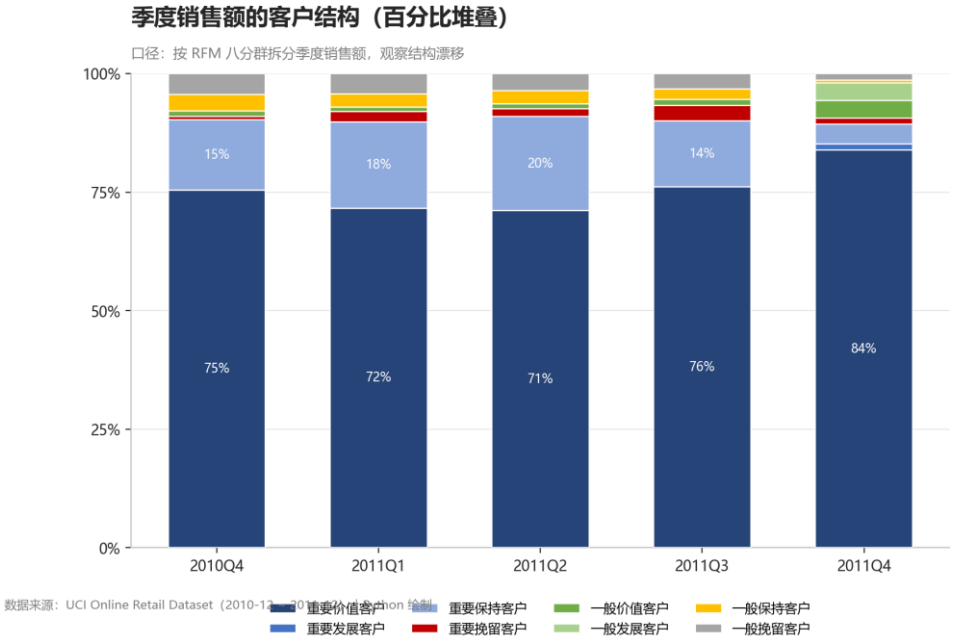


图 14　层叠柱形图（100%）：季度销售额的客户结构

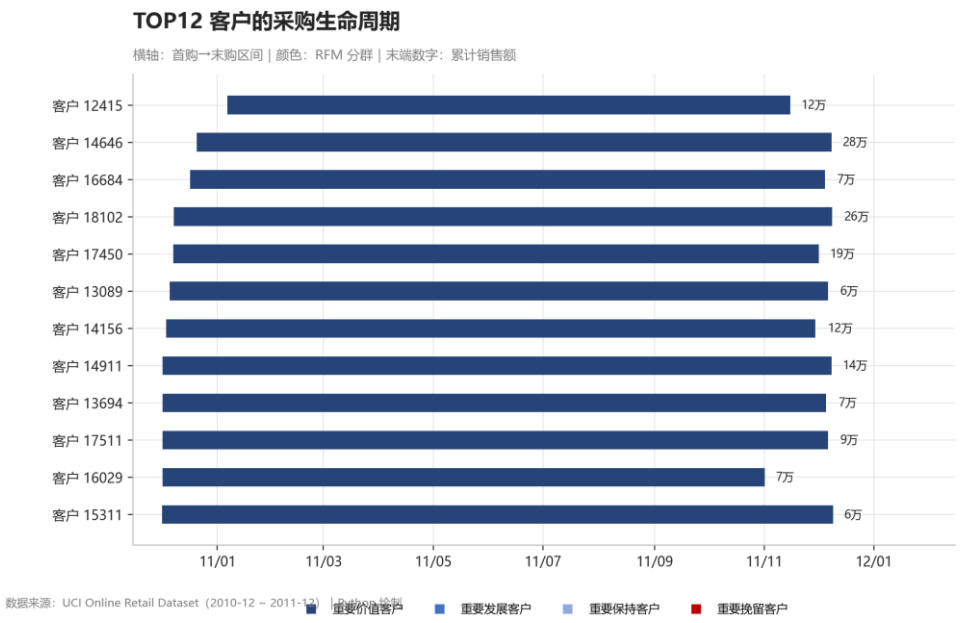


图 15　甘特图：TOP12 客户的采购生命周期

与 Excel 实现相比，Python 版本的差异主要体现在三处：一是版式可编程，同一套样式函数可复用到 23 张图，不存在手工对齐误差；二是数据与图层分离，改一个阈值即可整批重绘；三是可嵌入真实统计对象，例如甘特图的颜色直接取自 RFM 分群、玫瑰图的角度与半径由数据排序决定，而 Excel 版本通常需要手工摆位。劣势在于“所见即所得”的拖拽体验缺失，单张图的试错成本高于 Excel，这要求把样式抽象成函数一次性调好。

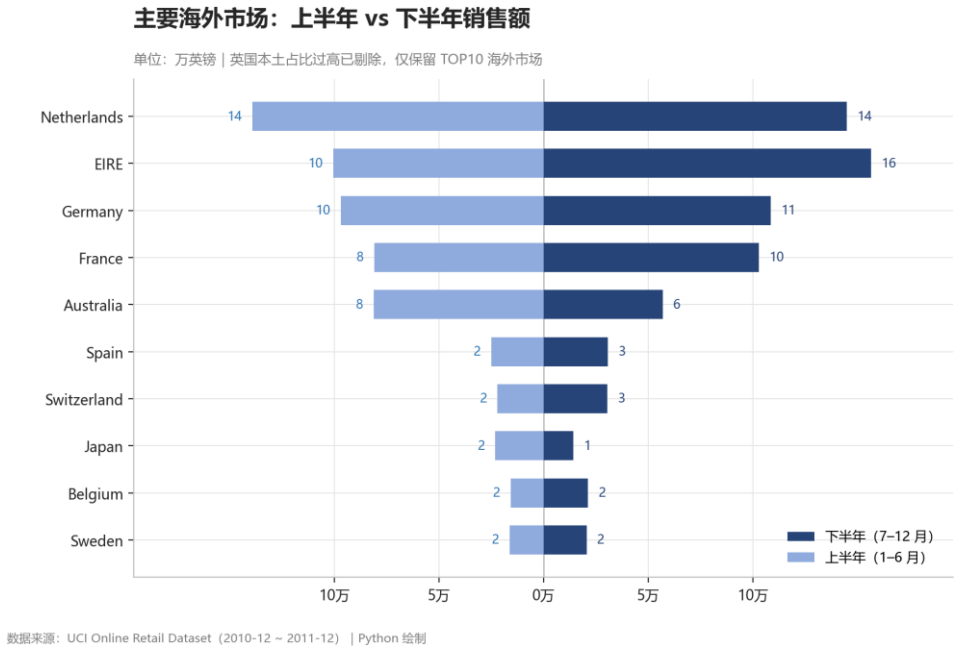


图 16　蝴蝶图：主要海外市场上半年 vs 下半年

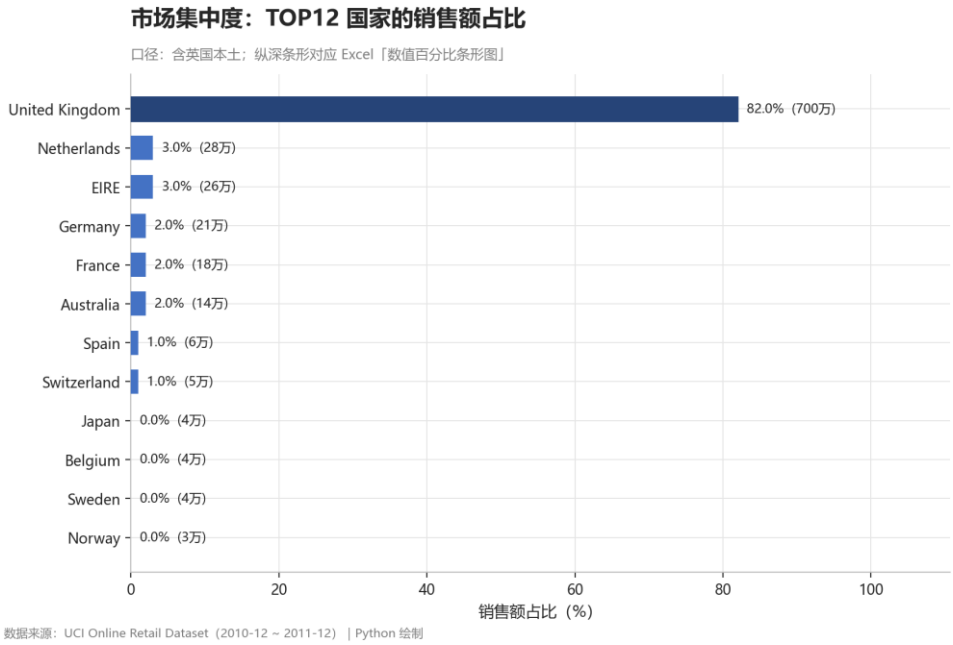


图 17　数值百分比条形图：国家销售额占比

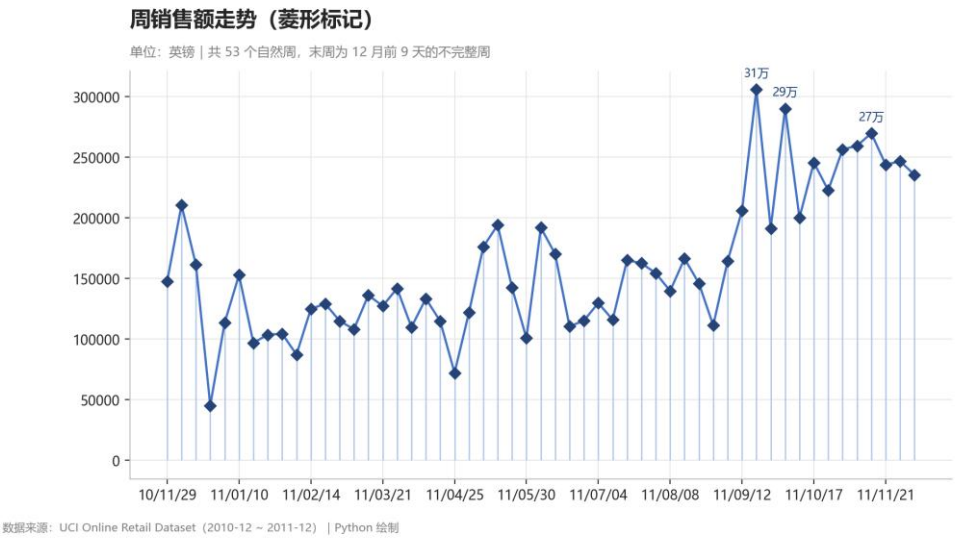


图 18　菱形走势图：周销售额

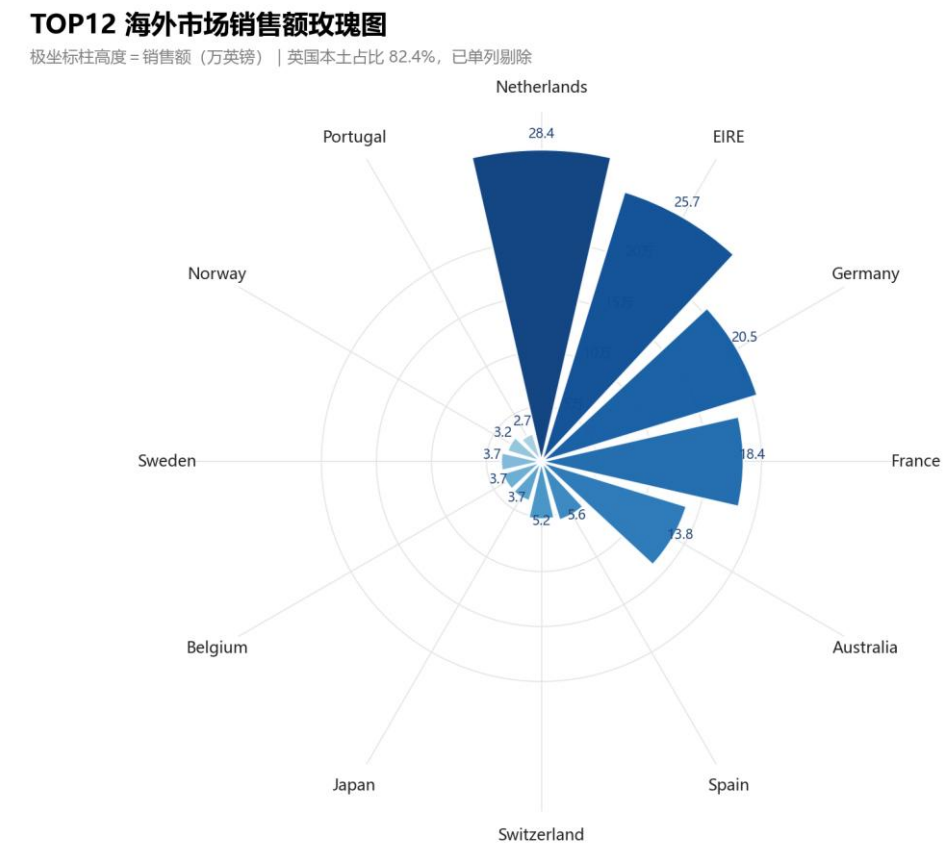


图 19　南丁格尔玫瑰图：TOP12 海外市场

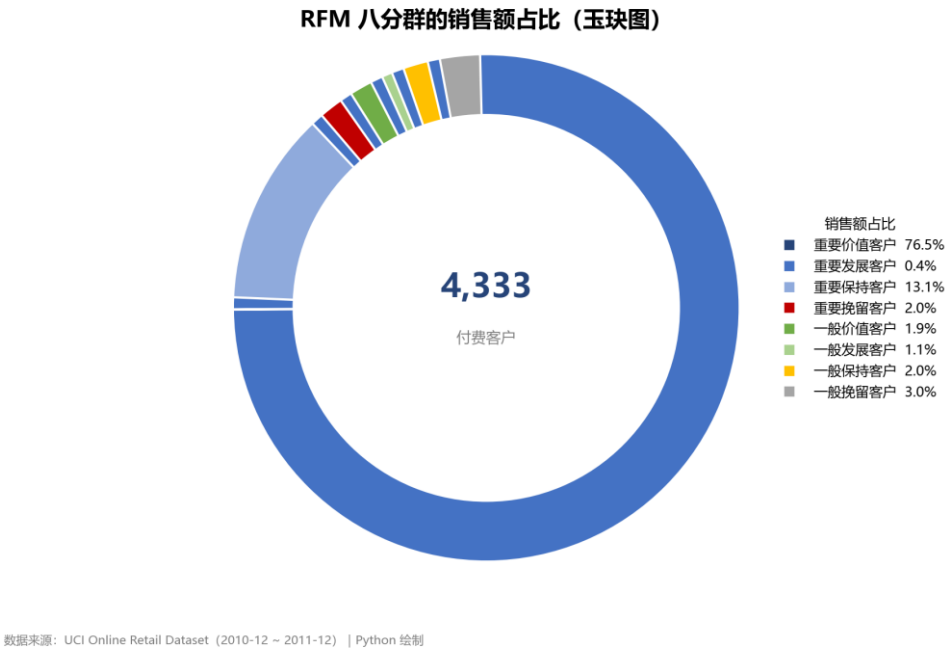


图 20　玉玦图：RFM 八分群销售额占比

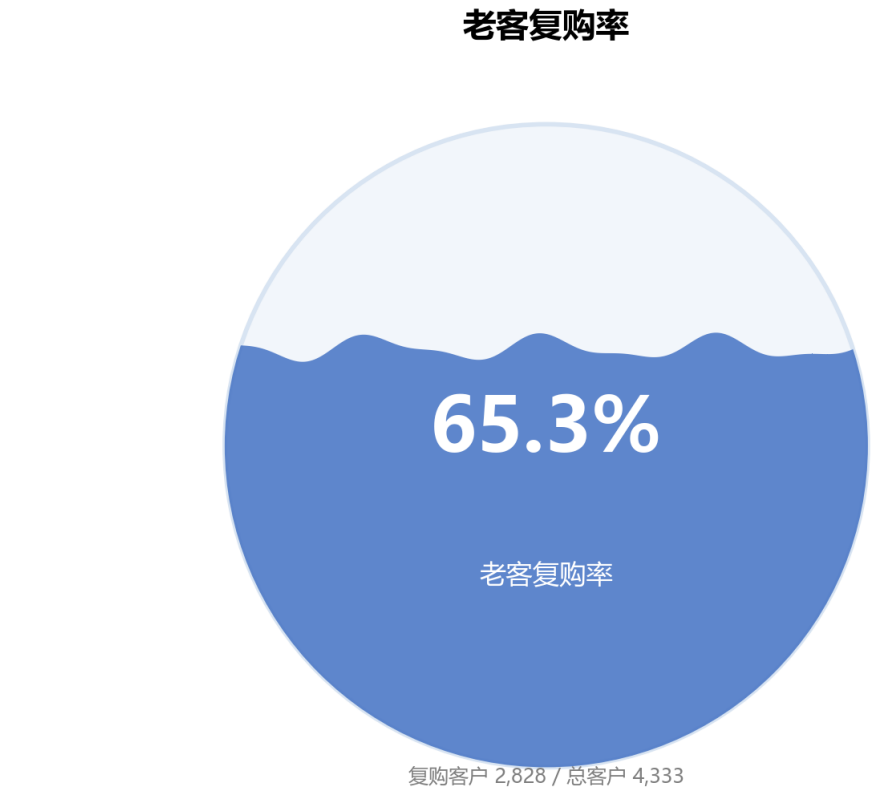


图 21　水球图：老客复购率 65.3%

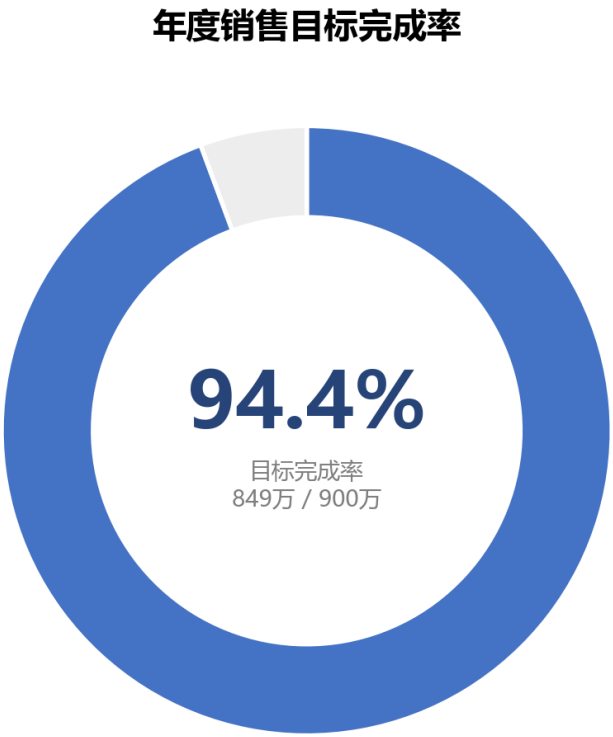


图 22　单值圆环图：年度目标完成率 94.4%

5.3　业务模型图（≥6 张）

第 4 章的六个模型各自对应一张核心业务图：RFM 气泡散点图（图 1）、八分群价值对比图（图 2）、同期群留存热力图（图 3）、关联规则气泡图（图 4）、SARIMA 预测图（图 5）、帕累托图（图 6）与波士顿矩阵（图 7），共 7 张，超过“≥6 张”的要求，且每张图都与一条可检验的商业结论绑定。此外补充了 ABC 分层对比图以衔接帕累托结论。

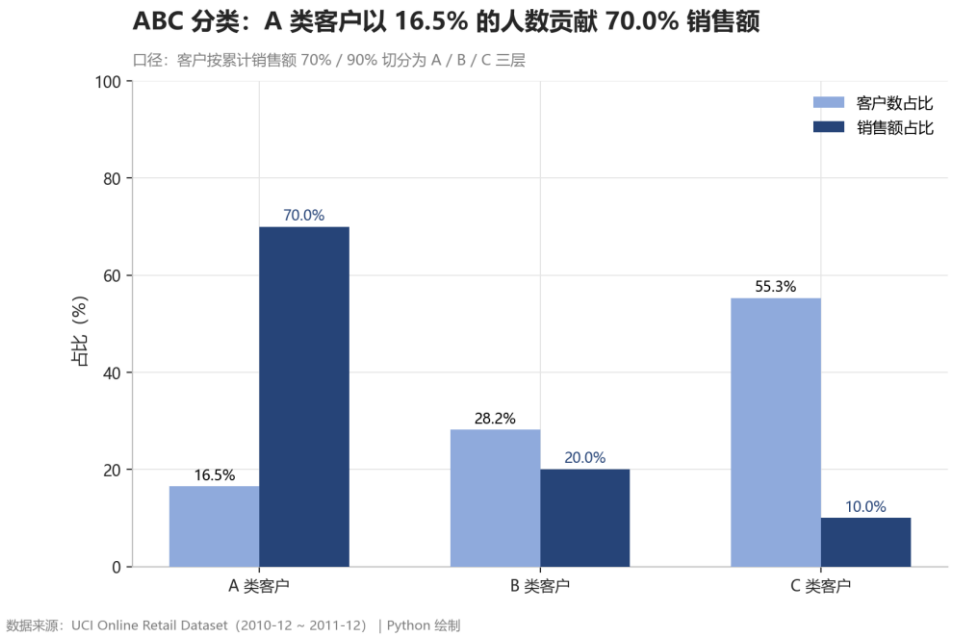


图 23　ABC 分层：A 类客户以 16.5% 的人数贡献 70.0% 销售额

5.4　交互式可视化大屏

大屏采用双实现：一份是基于 Pyecharts 的静态大屏（dashboard.html，1920×1080 深色主题，可直接双击打开、断网可用），另一份是基于 Streamlit 的交互应用（app.py），两者共用同一批清洗后数据。Pyecharts 版本包含 4 个 KPI 卡、月度趋势双轴图、世界地图、海外市场条形图、RFM 环形图、星期分布柱状图、TOP10 商品柱状图与关联规则明细表，共 10 个组件；Streamlit 版本在同样的组件基础上增加了 4 个筛选器（市场、日期区间、客户分层、客单价区间），筛选条件会同时驱动 KPI 卡、趋势图、结构图、热力图、帕累托曲线与明细表刷新，实现真正的联动与下钻。全部图表由 Python 生成，未使用 Power BI、Tableau、Fine BI 等任何 BI 软件。



图 24　Pyecharts 数据大屏（1920×1080 深色主题）

6　商业案例分析

6.1　案例背景

该商家是一家注册于英国的在线零售商，主营礼品、家居装饰、厨房用具与派对用品，客户以中小批发商、礼品店主与少量个人买家为主。经营的典型特征是“旺季极短、单笔金额大、客户重复采购但节奏不稳定”：11 月的销售额是月均水平的 1.7 倍，而单笔订单平均包含 21 个商品行，说明客户多为一次性补货。在这种模式下，客户关系的维护比拉新更划算——获取一位新批发客户的成本远高于让一位老客户提前一个月下单。

6.2　结果解读

第一，收入高度集中且集中在“近期活跃”的人群。重要价值客户（R、F、M 均高于中位数）仅占 32.9% 的人数，却贡献 76.5% 的销售额，其平均购买频次为 8.8 次、平均最近购买仅 17 天。这意味着该商家的收入并不依赖“广撒网”，而是依赖约 1400 位批发客户的持续补货。

第二，客户在首购后的第一个月内大量流失。次月平均留存 18.9%，第 11 个月仅 4.8%。结合 RFM 中“一般挽留客户”人数占比高达 23.5%，可以判断：大量客户只在一次促销或一次补货中成交，未形成稳定采购节奏。

第三，商品之间存在明确的成套购买结构。香草标记牌系列三款商品的提升度高达 81.7，茶具系列单条规则覆盖 476 张订单，说明客户的真实需求是“成套购买”而非“单件选购”，这与该商家经营礼品、派对用品的定位一致。

第四，销售节律稳定但预测受促销脉冲干扰。星期四为每周峰值、12 点为每日峰值，这类节律可以支撑排班与发货计划；但 11—12 月的促销爬坡无法被纯时序模型捕捉（MAPE 35.4%，略逊于季节朴素法的 31.6%），说明该商家的销售额更大程度由“促销日历”而非“自然趋势”驱动。

6.3 商业建议（5 条，可操作、有数据支撑）

（1）对重要价值客户做“账期 + 专属补货提醒”而非打折。这类客户 1,424 人、贡献 76.5% 销售额，价格敏感度低而对断货、账期敏感。建议为其配置 30 天账期与 SKU 级缺货预警，并在其历史补货周期（平均 8.8 次/年，约每 6 周一次）前 7 天推送补货清单。按该群体人均年贡献 4,563 英镑测算，补货频次每提升 5%，约可带来 32 万英镑增量。

（2）把挽回窗口前移到首购后 30 天。当前次月留存仅 18.9%，若通过“首购后第 14 天发送关联商品推荐 + 第 25 天发送限时复购券”把次月留存提升到 25%，按平均客户年贡献 1,959 英镑估算，留存率每提升 1 个百分点约带来 8.5 万英镑年增量，6 个百分点对应约 51 万英镑。该动作的边际成本仅为邮件与优惠券，投入产出比高于大规模拉新。

（3）把高提升度商品做成组合装。香草标记牌三件套（提升度 81.7）与 Regency 茶具系列（单规则覆盖 476 张订单）应改为“组合 SKU”上架，并在详情页互相导流；组合装还能降低拣货行数，缓解单笔 21 个商品行带来的仓储作业压力。

（4）按“周四峰值 + 11 月峰值”重排备货与人力。备货节奏应在 10 月中旬前完成圣诞品类入库，客服与仓配排班向周四、每日 10—14 点倾斜；由于周六歇业，周五下午应完成下周初订单的预打包。结合 SARIMA 给出的未来 28 天基线区间（合计约 76.2 万英镑），可将其作为“无促销情形”的库存下限，再叠加促销计划作为上限。

（5）把游客订单转化为可运营的客户资产。清洗中发现 131,354 行交易没有客户标识，对应约 150.96 万英镑销售额（约占总销售额的 15%）。建议在下

单流程中增加“注册即享首单 95 折”，把匿名交易比例压到 5% 以下；即便只转化其中三分之一，也能让客户级模型多覆盖约 5% 的收入，使后续 RFM 分层与留存分析更接近真实。

7 结论与展望

7.1 研究结论

本文以一份 54 万行的真实在线零售流水为对象，完成了从合规获取、十步清洗、六模型建模到23 张图表与双大屏呈现的端到端分析。主要结论有四：其一，收入高度集中于少数近期活跃的批发客户，26.8% 的客户贡献 80% 销售额；其二，客户留存的最大断点出现在首购后第一个月，次月留存仅 18.9%；其三，商品存在稳定的成套购买结构，成套化陈列与组合定价的空间明确；其四，销售节律由星期与促销日历共同驱动，纯时序模型只能刻画基线、无法替代促销计划。

7.2 局限性与展望

本文的局限主要有四：一是时间跨度仅 13 个月，且末月只有 9 天数据，无法做严格的同比分析，月度季节项也无法估计；二是数据不含成本与毛利，所有“价值”均以销售额衡量，未能识别“高销售额、低毛利”的伪优质客户；三是约 15% 的销售额缺少客户标识，客户级模型存在系统性低估；四是促销活动未被标注，导致 SARIMA 在圣诞窗口出现明显低估（偏差约 -23%）。后续可将成本表、促销日历作为外生变量接入 SARIMAX，或改用 Prophet 等支持节假日效应的模型，并把 RFM 与 K-Means 结合做更细的分群。

7.3 AI 使用披露

本文在以下环节使用了 AI 编程助手（DeepSeek / ChatGPT 类大模型）：① 生成脚本骨架与 matplotlib 样式函数，再逐图人工调参与核对；② 排查环境依赖与编码问题；③ 对论文初稿的语句做学术化润色。关键提示词示例：“用 matplotlib 复现 Excel 的渐变柱形图，柱体自上而下渐变，颜色取 Office 主题蓝（#9DC3E6 → #2F5597），并在柱顶标注数值”“对日销售额序列做 SARIMA 建模，季节周期 7，输出 56 天回测的 MAPE 与 RMSE 并画出 95% 置信区间”。所有数据结论均由脚本计算得出并人工复核，AI 未参与数据生成或结果篡改。

参考文献

[1] 郭宏远. Excel 数据可视化——从图表到数据大屏[M]. 北京: 清华大学出版社, 2023.

[2] Chen D. Online Retail Data Set[DB/OL]. UCI Machine Learning Repository, 2015. https://archive.ics.uci.edu/dataset/352/online+retail.

[3] Hughes A M. Strategic Database Marketing[M]. Chicago: Probus Publishing, 1994.

[4] Agrawal R, Srikant R. Fast Algorithms for Mining Association Rules[C]// Proceedings of the 20th VLDB Conference. 1994: 487-499.

[5] Hyndman R J, Athanasopoulos G. Forecasting: Principles and Practice[M]. 3rd ed. Melbourne: OTexts, 2021.

[6] McKinney W. Python for Data Analysis[M]. 3rd ed. Sebastopol: O'Reilly Media, 2022.

[7] Raschka S. MLxtend: Providing machine learning and data science utilities and extensions to Python's scientific computing stack[J]. Journal of Open Source Software, 2018, 3(24): 638.

[8] 贾俊平, 何晓群, 金勇进. 统计学[M]. 8 版. 北京: 中国人民大学出版社, 2021.

附录

A 核心代码片段

```
# 03_analysis.py —— RFM 八分类核心逻辑
REF_DATE = pd.Timestamp("2011-12-10")   # 数据最后一天的次日
rfm = (tx.groupby("CustomerID")
         .agg(R=("InvoiceDate",
                 lambda s: (REF_DATE - s.max()).days),
              F=("InvoiceNo", "nunique"),
              M=("Revenue", "sum"))
         .reset_index())
r_med = rfm["R"].median()
f_med = rfm["F"].median()
m_med = rfm["M"].median()
rfm["R_high"] = rfm["R"] <= r_med       # R 越小越近
rfm["F_high"] = rfm["F"] >= f_med
rfm["M_high"] = rfm["M"] >= m_med
# 8 种组合 -> 八分群名（重要/一般 × 价值/发展/保持/挽留）
```

B Gitee/GitHub 仓库链接与目录结构

仓库地址：https://github.com/<your-name>/online-retail-analysis（提交前替换为公开链接）

```
repo/
├── data/raw/           原始数据与 source_meta.json
├── data/clean/         清洗后四表 + schema + SQLite
├── scripts/            01_load ~ 05_dashboard + common.py
├── outputs/figures/    23 张 PNG + 图表索引.csv
├── outputs/tables/     20 张结果表 + analysis_results.json
├── outputs/dashboard/ dashboard.html（离线可开）
├── docs/               论文 docx/pdf、合规声明、build_paper.py
├── app.py              Streamlit 交互式仪表板
├── requirements.txt    依赖清单
├── run_all.py          一键复现入口
└── README.md           项目说明、复现步骤、图表索引
```

C　图表索引（fig01 – fig23）

编号	图表名称	对应模板/模型
fig01	渐变柱形图	模板复现 2.1.1
fig02	带平均线柱形图	模板复现 2.1.2
fig03	渐变圆角柱形图	模板复现 2.1.3
fig04	层叠柱形图（100%）	模板复现 2.1.5
fig05	蝴蝶图	模板复现 2.1.6
fig06	数值百分比条形图	模板复现 2.1.8
fig07	甘特图	模板复现 2.1.10
fig08	平滑折线图	模板复现 2.2.1
fig09	菱形走势图	模板复现 2.2.2
fig10	对比折线图	模板复现 2.2.3
fig11	单值圆环图	模板复现 2.3.1
fig12	南丁格尔玫瑰图	模板复现 2.3.8
fig13	玉玦图	模板复现 2.3.4
fig14	水球图	模板复现 2.3.2
fig15	柱形折线图	模板复现 2.4.1
fig16	RFM 气泡散点图	模型 M1 RFM
fig17	分群价值对比条形图	模型 M1 RFM
fig18	同期群留存热力图	模型 M2 同期群
fig19	帕累托图	模型 M5 帕累托/ABC
fig20	波士顿矩阵四象限图	模型 M6 波士顿矩阵
fig21	关联规则气泡图	模型 M3 Apriori
fig22	SARIMA 预测带图	模型 M4 预测
fig23	ABC 分层柱形图	模型 M5 帕累托/ABC